

Análisis de Asociación

1. Objetivo del análisis

El objetivo del análisis de asociación es identificar productos que suelen comprarse juntos dentro de las transacciones de venta. Esta técnica permite descubrir patrones de compra que pueden ayudar a la empresa a crear promociones, combos, recomendaciones de productos y estrategias de venta cruzada.

2. Dataset utilizado

Para este ejercicio se utilizó el archivo:

clave_F_asociacion.csv

Este archivo contiene información de ventas por transacción. Las columnas principales son




```
df.head()
```

	transaccion_id	cliente_id	fecha	categoria	item	cantidad	canal
0	F-T0001	F-C0058	2026-01-02	Ropa	Camiseta	4	Tienda
1	F-T0001	F-C0058	2026-01-02	Ciclismo	Casco	1	Tienda
2	F-T0001	F-C0058	2026-01-02	Futbol	Chaleco	1	Tienda
3	F-T0001	F-C0058	2026-01-02	Ciclismo	Luces	1	Tienda
4	F-T0002	F-C0005	2026-01-09	Ciclismo	Casco	1	App

3. Limpieza de datos

Antes de aplicar el algoritmo Apriori, se revisaron valores nulos, registros duplicados y tipos de datos.



```
df.isnull().sum()
```

	0
transaccion_id	0
cliente_id	0
fecha	0
categoria	0
item	0
cantidad	0
canal	1

dtype: int64

```
df.duplicated().sum()
```

np.int64(1)

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 605 entries, 0 to 604
Data columns (total 7 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   transaccion_id         605 non-null    object  
1   cliente_id             605 non-null    object  
2   fecha                  605 non-null    object  
3   categoria              605 non-null    object  
4   item                   605 non-null    object  
5   cantidad               605 non-null    int64   
6   canal                  605 non-null    object  
dtypes: int64(1), object(6)
memory usage: 33.2+ KB
```

El Dataset cuanto con 6 valores de tipo Object y 1 valor de tipon integer

Durante la revisión se identificó un valor nulo en la columna canal y un registro duplicado. El valor nulo fue reemplazado por "No especificado" para no eliminar información útil de la transacción. Además, el registro duplicado fue eliminado para evitar que una compra se contabilizara más de una vez.

Código utilizado:

```
# Rellenar valores nulos en la columna canal
df["canal"] = df["canal"].fillna("No especificado")

# Eliminar registros duplicados
df = df.drop_duplicates()
```

Después de la limpieza, se verificó nuevamente el dataset y ya no se encontraron valores nulos ni duplicados.

Valores nulos y duplicados despues de la limpieza

```
df.isnull().sum()

...
0
transaccion_id 0
cliente_id    0
fecha         0
categoria     0
item          0
cantidad      0
canal         0

dtype: int64

df.duplicated().sum()

np.int64(0)
```

4. Preparación de los datos

Para aplicar reglas de asociación, fue necesario transformar el dataset a una tabla transaccional. En esta tabla, cada fila representa una transacción y cada columna representa un producto.

Los valores se convirtieron a:

Valor	Significado
1	El producto fue comprado en la transacción
0	El producto no fue comprado en la transacción

Código utilizado:

```
Preparar los datos para Apriori

tabla_transacciones = df.groupby(["transaccion_id", "item"])["cantidad"].sum().unstack().fillna(0)
tabla_transacciones.head()
```

	item	Balon	Banda_elastica	Barra_energia	Bebida_isotonica	Calcetas	Camiseta	Candado	Casco	Chaleco	Conos	Creatina
transaccion_id												
	F-T0001	0.0	0.0	0.0	0.0	0.0	4.0	0.0	1.0	1.0	0.0	0.0
	F-T0002	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0
	F-T0003	0.0	1.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0
	F-T0004	0.0	0.0	0.0	0.0	4.0	0.0	0.0	0.0	0.0	0.0	1.0
	F-T0005	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0

```
Convertir cantidades a 0 y 1

tabla_transacciones = tabla_transacciones.applymap(lambda x: 1 if x > 0 else 0)
tabla_transacciones.head()
```

```
... /tmp/ipykernel_24967/805712911.py:1: FutureWarning: DataFrame.applymap has been deprecated. Use DataFrame.map instead.
      tabla_transacciones = tabla_transacciones.applymap(lambda x: 1 if x > 0 else 0)
```

	item	Balon	Banda_elastica	Barra_energia	Bebida_isotonica	Calcetas	Camiseta	Candado	Casco	Chaleco	Conos	Creatina
transaccion_id												
	F-T0001	0	0	0	0	0	1	0	1	1	0	0
	F-T0002	0	0	0	0	0	0	0	1	0	0	0
	F-T0003	0	1	0	0	0	0	1	0	0	0	0
	F-T0004	0	0	0	0	1	0	0	0	0	0	1
	F-T0005	1	0	0	0	0	0	0	0	0	1	0

Esta preparación es necesaria porque el algoritmo Apriori trabaja con presencia o ausencia de productos, no con cantidades.

5. Aplicación del algoritmo Apriori

Se aplicó el algoritmo Apriori para encontrar productos o combinaciones de productos que aparecen con frecuencia en las transacciones.

Código utilizado:

Aplicar algoritmo Apriori

```
itemsets_frecuentes = apriori(
    tabla_transacciones,
    min_support=0.03,
    use_colnames=True
)

itemsets_frecuentes.head()
```

	support	itemsets
0	0.226316	(Balon)
1	0.252632	(Banda_elastica)
2	0.105263	(Barra_energia)
3	0.152632	(Bebida_isotonica)
4	0.252632	(Calcetas)

Ordenar los itemsets frecuentes

```
itemsets_frecuentes = itemsets_frecuentes.sort_values(by="support", ascending=False)

itemsets_frecuentes.head(10)
```

	support	itemsets
18	0.268421	(Tenis)
13	0.257895	(Luces)
1	0.252632	(Banda_elastica)
4	0.252632	(Calcetas)
0	0.226316	(Balon)
7	0.226316	(Casco)
15	0.215789	(Mat)
9	0.210526	(Conos)
3	0.152632	(Bebida_isotonica)
47	0.152632	(Calcetas, Tenis)

Se utilizó un soporte mínimo de 0.03, lo que significa que se buscaron combinaciones que aparecen al menos en el 3% de las transacciones.

6. Generación de reglas de asociación

Después de encontrar los itemsets frecuentes, se generaron reglas de asociación usando las métricas de soporte, confianza y lift.

Código utilizado:

Generar reglas de asociación

```
reglas = association_rules(
    itemsets_frecuentes,
    metric="confidence",
    min_threshold=0.2
)

reglas.head()
```

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift	representativity	leverage	conviction
0	(Calcetas)	(Tenis)	0.252632	0.268421	0.152632	0.604167	2.250817	1.0	0.084820	1.848199
1	(Tenis)	(Calcetas)	0.268421	0.252632	0.152632	0.568627	2.250817	1.0	0.084820	1.732536
2	(Banda_elastica)	(Mat)	0.252632	0.215789	0.136842	0.541667	2.510163	1.0	0.082327	1.711005
3	(Mat)	(Banda_elastica)	0.215789	0.252632	0.136842	0.634146	2.510163	1.0	0.082327	2.042807
4	(Casco)	(Luces)	0.226316	0.257895	0.121053	0.534884	2.074039	1.0	0.062687	1.595526

Seleccionar columnas importantes

```
reglas_importantes = reglas[
    ["antecedents", "consequents", "support", "confidence", "lift"]
]

reglas_importantes.head(10)
```

	antecedents	consequents	support	confidence	lift
0	(Calcetas)	(Tenis)	0.152632	0.604167	2.250817
1	(Tenis)	(Calcetas)	0.152632	0.568627	2.250817
2	(Banda_elastica)	(Mat)	0.136842	0.541667	2.510163
3	(Mat)	(Banda_elastica)	0.136842	0.634146	2.510163
4	(Casco)	(Luces)	0.121053	0.534884	2.074039
5	(Luces)	(Casco)	0.121053	0.469388	2.074039
6	(Conos)	(Balon)	0.115789	0.550000	2.430233
7	(Balon)	(Conos)	0.115789	0.511628	2.430233
8	(Calcetas)	(Guantes_bici)	0.057895	0.229167	1.674679
9	(Guantes_bici)	(Calcetas)	0.057895	0.423077	1.674679

Ordenar las mejores reglas

```
reglas_importantes = reglas_importantes.sort_values(by="lift", ascending=False)
reglas_importantes.head(10)
```

	antecedents	consequents	support	confidence	lift
47	(Balon, Tenis)	(Calcetas)	0.031579	0.750000	2.968750
51	(Tenis, Guantes_bici)	(Calcetas)	0.031579	0.750000	2.968750
55	(Tenis, Luces)	(Calcetas)	0.031579	0.666667	2.638889
3	(Mat)	(Banda_elastica)	0.136842	0.634146	2.510163
2	(Banda_elastica)	(Mat)	0.136842	0.541667	2.510163
48	(Calcetas, Balon)	(Tenis)	0.031579	0.666667	2.483660
7	(Balon)	(Conos)	0.115789	0.511628	2.430233
6	(Conos)	(Balon)	0.115789	0.550000	2.430233
0	(Calcetas)	(Tenis)	0.152632	0.604167	2.250817
1	(Tenis)	(Calcetas)	0.152632	0.568627	2.250817

Mostrar las 10 reglas más relevantes

```
top_10_reglas = reglas_importantes.head(10)
top_10_reglas
```

	antecedents	consequents	support	confidence	lift
47	(Balon, Tenis)	(Calcetas)	0.031579	0.750000	2.968750
51	(Tenis, Guantes_bici)	(Calcetas)	0.031579	0.750000	2.968750
55	(Tenis, Luces)	(Calcetas)	0.031579	0.666667	2.638889
3	(Mat)	(Banda_elastica)	0.136842	0.634146	2.510163
2	(Banda_elastica)	(Mat)	0.136842	0.541667	2.510163
48	(Calcetas, Balon)	(Tenis)	0.031579	0.666667	2.483660
7	(Balon)	(Conos)	0.115789	0.511628	2.430233
6	(Conos)	(Balon)	0.115789	0.550000	2.430233
0	(Calcetas)	(Tenis)	0.152632	0.604167	2.250817
1	(Tenis)	(Calcetas)	0.152632	0.568627	2.250817

El soporte indica qué tan frecuente aparece una combinación de productos dentro del total de transacciones.

La confianza indica la probabilidad de que un cliente compre un producto B cuando ya compró un producto A.

El lift indica qué tan fuerte es la relación entre dos productos. Si el lift es mayor que 1, significa que existe una asociación positiva entre los productos.

7. Evidencia de resultados

En la siguientes imagenes se muestran las 10 reglas de asociación más relevantes ordenadas por la métrica lift.

```
Regla: Si compra ['Balon', 'Tenis'], también compra ['Calcetas']
Soporte: 0.03
Confianza: 0.75
Lift: 2.97
-----
Regla: Si compra ['Tenis', 'Guantes_bici'], también compra ['Calcetas']
Soporte: 0.03
Confianza: 0.75
Lift: 2.97
-----
Regla: Si compra ['Tenis', 'Luces'], también compra ['Calcetas']
Soporte: 0.03
Confianza: 0.67
Lift: 2.64
-----
Regla: Si compra ['Mat'], también compra ['Banda_elastica']
Soporte: 0.14
Confianza: 0.63
Lift: 2.51
-----
Regla: Si compra ['Banda_elastica'], también compra ['Mat']
Soporte: 0.14
Confianza: 0.54
Lift: 2.51
-----
Regla: Si compra ['Calcetas', 'Balon'], también compra ['Tenis']
Soporte: 0.03
Confianza: 0.67
Lift: 2.48
```

```
Regla: Si compra ['Balon'], también compra ['Conos']
Soporte: 0.12
Confianza: 0.51
Lift: 2.43
-----
Regla: Si compra ['Conos'], también compra ['Balon']
Soporte: 0.12
Confianza: 0.55
Lift: 2.43
-----
Regla: Si compra ['Calcetas'], también compra ['Tenis']
Soporte: 0.15
Confianza: 0.60
Lift: 2.25
-----
Regla: Si compra ['Tenis'], también compra ['Calcetas']
Soporte: 0.15
Confianza: 0.57
Lift: 2.25
-----
```

8. Interpretación de reglas

Regla 1:

Si un cliente compra Balón y Tenis, también compra Calcetas.

Interpretación de negocio:

Los clientes que compran productos relacionados con fútbol o deporte, como balón y tenis, también suelen comprar calcetas. La empresa podría crear un combo deportivo que incluya estos tres productos.

Regla 2:

Si un cliente compra Tenis y Guantes_bici, también compra Calcetas.

Interpretación de negocio:

Esta regla muestra que las calcetas pueden funcionar como producto complementario para clientes que compran artículos deportivos. Se podrían sugerir calcetas al momento de comprar tenis o accesorios de ciclismo.

Regla 3:

Si un cliente compra Tenis y Luces, también compra Calcetas.

Interpretación de negocio:

Los clientes que compran tenis y luces, posiblemente relacionados con actividad deportiva o ciclismo, también compran calcetas. Esto puede aprovecharse mediante recomendaciones automáticas en la app o en tienda.

Regla 4:

Si un cliente compra Mat, también compra Banda_elastica.

Interpretación de negocio:

El mat y la banda elástica son productos relacionados con ejercicio, entrenamiento o yoga. La empresa podría ofrecerlos juntos como un kit de entrenamiento en casa.

Regla 5:

Si un cliente compra Banda_elastica, también compra Mat.

Interpretación de negocio:

Esta regla refuerza la relación entre productos de entrenamiento. Se recomienda colocar ambos productos cerca en tienda o mostrarlos juntos en la aplicación.

9. Recomendaciones comerciales

A partir de las reglas de asociación encontradas, se proponen las siguientes recomendaciones:

- Crear combos o paquetes promocionales con los productos que aparecen relacionados en las reglas más fuertes.
- Sugerir productos complementarios en la aplicación o sistema de ventas cuando el cliente agregue un producto relacionado.
- Colocar productos asociados cerca uno del otro en tienda física para aumentar la probabilidad de compra conjunta.
- Diseñar campañas de venta cruzada basadas en los productos que presentan mayor confianza y lift.

10. Conclusión del análisis de asociación

El análisis de asociación permitió identificar productos que suelen comprarse juntos dentro del dataset de ventas. Mediante el algoritmo Apriori se generaron reglas basadas en soporte, confianza y lift, lo que permitió descubrir relaciones útiles entre productos.

Estos resultados pueden ayudar a la empresa a mejorar sus estrategias comerciales mediante promociones, combos, recomendaciones personalizadas y venta cruzada. En conclusión, las reglas de asociación son una técnica útil para comprender el comportamiento de compra de los clientes y aprovecharlo en la toma de decisiones.